



TECH CHALLENGE II · FIAP · DATA ANALYTICS

Classificando a Qualidade de Vinhos com Machine Learning

Uma jornada de análise exploratória e modelagem preditiva para apoiar decisões na indústria vitivinícola

1

CONTEXTO DO PROBLEMA

Por Que Prever a Qualidade do Vinho?

 O Desafio Tradicional A avaliação sensorial por especialistas é subjetiva, lenta e dependente da experiência individual dos avaliadores.	 A Oportunidade com Dados Dados físico-químicos coletados na produção podem ser usados para prever a qualidade de forma objetiva e escalável.
 O Impacto Esperado Modelos preditivos apoiam enólogos na tomada de decisão, permitindo ajustes no processo produtivo e padronização da qualidade.	



1

2

DATASET

Wine Quality Dataset — Fonte: Kaggle



O dataset contém **informações físico-químicas** de **1143 amostras de vinho**, com uma nota de qualidade atribuída por especialistas como variável alvo.

11 Variáveis físico-químicas

Acidez fixa e volátil, ácido cítrico, açúcar residual, cloretos, SO_2 livre e total, densidade, pH, sulfatos e teor alcoólico


Nota de qualidade (Classificação Binária)

Alta Qualidade: nota ≥ 7 | **Baixa/Média:** nota < 7

3

METODOLOGIA

Pipeline de Análise e Modelagem



Cada etapa foi executada de forma iterativa, garantindo rigor analítico e rastreabilidade das decisões tomadas ao longo do projeto.

2

4

EDA - DISTRIBUIÇÃO

Distribuição das Variáveis Físico-Químicas

A análise de distribuição revelou padrões relevantes: o **teor alcoólico** e a **acidez volátil** apresentaram as maiores **variações entre as amostras**, enquanto pH e densidade mostraram distribuições mais concentradas.

A maioria das variáveis apresentou distribuição assimétrica, indicando a necessidade de transformação ou uso de modelos robustos a outliers.



5

EDA - CORRELAÇÕES

O Que os Dados Revelam Sobre Qualidade?

▲ Teor Alcoólico

Correlação positiva com qualidade. Vinhos com maior graduação alcoólica tendem a receber notas mais altas.

▼ Acidez Volátil

Correlação negativa significativa. Alta acidez volátil está associada a defeitos sensoriais e menor qualidade.

▲ Ácido Cítrico

Correlação positiva moderada. Contribui para frescor e equilíbrio, valorizado pelos avaliadores.

▲ Sulfatos


Correlação positiva, associados a melhor avaliação

3

6

EDA · BALANCEAMENTO

As Classes estão equilibradas?



Desequilíbrio Identificado

Aproximadamente **14% das amostras** pertencem à classe de **alta qualidade**.

Este desbalanceamento pode enviesar o modelo, e gerar alta acurácia com baixa capacidade de generalização

Assim priorizamos métricas como F1-Score e AUC-ROC, invés da acurácia e aplicamos ponderação de classes no treino dos modelos

7

PRÉ-PROCESSAMENTO

Preparando os Dados para Modelagem



Integridade dos dados

Ausência de dados faltantes no dataset original — validação da integridade das amostras.



Normalização / Padronização

Aplicação de StandardScaler para variáveis com escalas distintas (ex: SO₂ vs. pH).



Feature Engineering

Variáveis derivadas (acidez total, álcool/densidade) foram avaliadas e **descartadas** por não superarem as originais.



Tratamento do Desbalanceamento

Uso de ponderação de classes e split estratificado, preservando a proporção real das classes. .

4

8

MODELAGEM

Comparação - Modelos de Classificação

Regressão Logística

Base linear e interpretável

★ RECOMENDADO

Random Forest

Ensemble robusto a outliers

Gradient Boosting

Ensemble sequencial de alto desempenho

SVM (RBF)

Fronteiras não lineares, melhor recall

Teste de 4 modelos de classificação

A escolha contempla um modelo **linear e interpretável** (Regressão Logística) como baseline, e um modelo **ensemble não-linear** (Random Forest) para capturar relações complexas entre as variáveis físico-químicas.

A comparação permite avaliar o trade-off entre interpretabilidade e poder preditivo — essencial para justificar a escolha final ao negócio.

Random Forest entrega o melhor equilíbrio

Modelo	Acurácia	Precisão	Recall	F1	ROC-AUC
Random Forest ★	0,913	0,800	0,500	0,615	0,910
Gradient Boosting	0,900	0,667	0,562	0,610	0,879
SVM (RBF)	0,817	0,411	0,719	0,523	0,870
Regressão Logística	0,799	0,379	0,688	0,489	0,850

O Random Forest lidera em F1 e ROC-AUC. SVM e Regressão Logística alcançam recall maior, mas às custas de muita precisão

9

LEITURA DE NEGÓCIO – LIMIAR DE DECISÃO

Ajustar o limiar muda o custo do erro

Limiar	Precisão	Recall	F1
0,5 (padrão)	0,800	0,500	0,615
0,4 ★	0,750	0,656	0,700
0,3	0,579	0,688	0,629
0,2	0,469	0,719	

No limiar padrão (0,5), o modelo identifica apenas **metade** dos vinhos de alta qualidade.

Baixar para **0,4** eleva o F1 para **0,70** mantendo precisão razoável.

O ponto ideal depende do erro mais caro: deixar passar um vinho bom (falso negativo) ou rotular um comum como especial (falso positivo)



5

10

CONCLUSÕES

Principais drivers de qualidade

**Teor Alcoólico**

Variável de maior influência positiva. Reforça o valor do controle da fermentação na busca por notas mais altas.

**Acidez volátil**

Principal fator negativo. Conservação e higiene no processo ajudam a evitar defeitos sensoriais.

Os drivers identificados pelo modelo estão alinhados ao conhecimento enológico tradicional — isso indica que o modelo capturou relações reais, e não ruído dos dados.

11

CONCLUSÕES

Do dado a decisão de produção

Drivers de qualidade

Teor alcoólico e acidez volátil são as variáveis de maior influência — alinhadas ao conhecimento enológico.

Implicações para a produção

Controle rigoroso da fermentação e da conservação pode elevar sistematicamente a qualidade final.

Próximos passos

Testar XGBoost e disponibilizar o Random Forest como ferramenta de apoio à decisão do enólogo.

Os fatores apontados pelo modelo estão totalmente alinhados ao que a prática enológica já reconhece como determinante de qualidade.

Isso mostra que o **Random Forest** está capturando relações reais do processo, não apenas padrões aleatórios.

Por isso, ele se destaca como uma **ferramenta prática de apoio ao enólogo**, ajudando a tomar decisões mais seguras e consistentes sobre a qualidade dos vinhos.

6

12