



TECH CHALLENGE II · FIAP · DATA ANALYTICS

Classificando a Qualidade de Vinhos com Machine Learning

Uma jornada de análise exploratória e modelagem preditiva para apoiar decisões na indústria vitivinícola

Por Que Prever a Qualidade do Vinho?



O Desafio Tradicional

A avaliação sensorial por especialistas é subjetiva, lenta e dependente da experiência individual dos avaliadores.



A Oportunidade com Dados

Dados físico-químicos coletados na produção podem ser usados para prever a qualidade de forma objetiva e escalável.



O Impacto Esperado

Modelos preditivos apoiam enólogos na tomada de decisão, permitindo ajustes no processo produtivo e padronização da qualidade.



Wine Quality Dataset — Fonte: Kaggle



O dataset contém **informações físico-químicas** de amostras de vinho, com uma nota de qualidade atribuída por especialistas como variável alvo.

12 Variáveis

Acidez fixa e volátil, ácido cítrico, açúcar residual, cloretos, SO_2 livre e total, densidade, pH, sulfatos e teor alcoólico

Classificação Binária

Alta Qualidade: nota ≥ 7 | **Baixa/Média:** nota < 7

Pipeline de Análise e Modelagem



Compreensão

Exploratória

Pré-process.


Desenvolvimento

Cada etapa foi executada de forma iterativa, garantindo rigor analítico e rastreabilidade das decisões tomadas ao longo do projeto.

Distribuição das Variáveis Físico-Químicas

A análise de distribuição revelou padrões relevantes: o **teor alcoólico** e a **acidez volátil** apresentaram as maiores variações entre as amostras, enquanto pH e densidade mostraram distribuições mais concentradas.

- ❑ A maioria das variáveis apresentou distribuição assimétrica, indicando a necessidade de transformação ou uso de modelos robustos a outliers.



O Que os Dados Revelam Sobre Qualidade?

▲ Teor Alcoólico

Correlação positiva com qualidade. Vinhos com maior graduação alcoólica tendem a receber notas mais altas.

▼ Acidez Volátil

Correlação negativa significativa. Alta acidez volátil está associada a defeitos sensoriais e menor qualidade.


▲ Ácido Cítrico

Correlação positiva moderada. Contribui para frescor e equilíbrio, valorizado pelos avaliadores.

▼ SO₂ Total

Correlação negativa leve. Excesso de conservantes pode indicar compensação por falhas no processo.

As Classes Estão Equilibradas?



Desequilíbrio Identificado

Aproximadamente **75% das amostras** pertencem à classe de baixa/média qualidade, criando um desbalanceamento que pode enviesar os modelos preditivos.

- Risco de alta acurácia com baixa capacidade discriminativa
- Necessidade de técnicas como SMOTE ou ponderação de classes
- Métricas como F1-Score e AUC-ROC são mais adequadas

Preparando os Dados para Modelagem



Verificação de Missing Values

Ausência de dados faltantes no dataset original — validação da integridade das amostras.



Normalização / Padronização

Aplicação de StandardScaler para variáveis com escalas distintas (ex: SO_2 vs. pH).



Feature Engineering

Criação de razões entre variáveis correlacionadas (ex: SO_2 livre / SO_2 total) para capturar relações não lineares.



Tratamento do Desbalanceamento

Aplicação de SMOTE ou class_weight para garantir aprendizado equitativo entre as classes.

Modelos de Classificação em Comparação



Regressão Logística

-  simples e interpretável
-  modelo base (baseline)
-  treinamento rápido
-  fronteira de decisão linear



Floresta Aleatória

-  método de ensemble
-  lida com não linearidade
-  importância de características
-  robusto a outliers
-  melhor para dados desbalanceados

Por Que Esses Modelos?

A escolha contempla um modelo **linear e interpretável** (Regressão Logística) como o baseline, e um modelo **ensemble não-linear** (Random Forest) para capturar relações complexas entre as variáveis físico-químicas.

A comparação permite avaliar o trade-off entre interpretabilidade e poder preditivo — essencial para justificar a escolha final ao negócio.

Próximos Passos e Implicações



Principais Drivers de Qualidade

Teor alcoólico e acidez volátil são as variáveis de maior influência — alinhadas ao conhecimento enológico tradicional.



Implicações para a Produção

Controle rigoroso da fermentação e conservação pode elevar sistematicamente a qualidade final do vinho.



Próximas Etapas

Validação cruzada, teste com XGBoost/Gradient Boosting e deploy do modelo como ferramenta de apoio à decisão.

